ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ

ΤΜΗΜΑ ΨΗΦΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ

Μεταπτυχιακό Πρόγραμμα Σπουδών «Πληροφοριακά Συστήματα & Υπηρεσίες»

Μάθημα: Προγραμματισμός και Υποδομές Μεγάλων Δεδομένων Python και Νεφοϋπολογιστική

Τεχνική Αναφορά (Μέρος Α)

Αναπαραγωγή αλγοριθμικού μοντέλου για βελτιστοποίηση Concentrated Inspection Campaign (CIC) σε δεδομένα Port State Control (PSC) του Paris MoU

Φοιτητές

Όνομα	Επώνυμο	Αριθμός Μητρώου	Email
Antonios	Papakonstantinou	me25028	antonhspap@icloud.com
Dimitrios	Kostiris	me25021	dimkostir@gmail.com

Πίνακας Περιεχομένων

Contents

1. Εισαγωγή 4

2. Στόχος και ερευνητικό ερώτημα 4

3. Περιγραφή δεδομένων και πηγών 5

3.1 Πηγή δεδομένων: Paris MoU THETIS-PSC 5

3.2 Σχήμα (schema) και βασικές μεταβλητές 5

3.3 Αναπαράσταση δεδομένων ως πίνακας συχνοτήτων (matrix) 5

4. Συνοπτική αρχιτεκτονική λύσης και ροή εργασίας 6

5. Υλοποίηση απόκτησης και μετασχηματισμού δεδομένων (data.py) 7

5.1 Αυθεντικοποίηση και λήψη αρχείων μέσω API 7

5.2 Αποσυμπίεση και εντοπισμός XML 7

5.3 Parsing XML με iterparse και διαχείριση μνήμης 7

5.4 Εξαγωγή ShipType 7

5.5 Εξαγωγή Deficiency Code 8

5.6 Aggregation: μέτρηση συχνοτήτων και παραγωγή matrix 8

6. Προετοιμασία δεδομένων και περιγραφική ανάλυση (notebook.ipynb) 9

6.1 Φόρτωση matrix και βασικά στατιστικά 9

6.2 Ορισμός decision matrix E και alternatives A 9

7. Συνοπτική θεωρία και υλοποίηση αλγορίθμων 9

7.1 Grey Relational Analysis (GRA) 9

7.1.1 Σημεία υλοποίησης στο notebook 10

7.2 TOPSIS 10

7.2.1 Σημεία υλοποίησης στο notebook 10

7.3 Three-Sigma Rule (κανόνας 3σ) 11

7.3.1 Σημεία υλοποίησης στο notebook 11

8. Ερμηνεία αποτελεσμάτων και σύνδεση με το paper 11

9. Συμπεράσματα 12

Αναλυτικότερη περιγραφή αλγορίθμων και παραδείγματα υπολογισμού 13

1 GRA – Παράδειγμα με μικρό πίνακα 13

2 TOPSIS – Παράδειγμα και ερμηνεία του Closeness Coefficient 13
D.3 Three-Sigma – γιατί 3σ και πώς χρησιμοποιείται για επιλογή inspection items..... 14

1. Εισαγωγή

Η ασφάλεια της ναυτιλίας αποτελεί κρίσιμο παράγοντα για τη διεθνή οικονομία, το περιβάλλον και την ανθρώπινη ζωή στη θάλασσα. Για τη διασφάλιση υψηλών προτύπων ασφάλειας, εφαρμόζεται το Port State Control (PSC), δηλαδή ένα σύστημα επιθεωρήσεων σε πλοία που καταπλέουν σε λιμάνια, με στόχο τον εντοπισμό ελλείψεων (deficiencies), παραβάσεων κανονισμών ή συνθηκών που ενδέχεται να θέσουν σε κίνδυνο το πλοίο, το πλήρωμα, το φορτίο ή το περιβάλλον.

Στο πλαίσιο των MoU (Memorandum of Understanding) για το PSC, το Paris MoU αποτελεί έναν από τους σημαντικότερους περιφερειακούς μηχανισμούς επιθεώρησης. Πέρα από το κανονικό καθεστώς επιθεωρήσεων PSC, εφαρμόζεται και ο θεσμός της Concentrated Inspection Campaign (CIC): μια στοχευμένη καμπάνια επιθεωρήσεων, με συγκεκριμένη θεματική, για τρεις συνεχόμενους μήνες κάθε έτος, συνήθως προς το τέλος του έτους.

Το paper που αναπαράχθηκε στην παρούσα εργασία προτείνει έναν βελτιωμένο μηχανισμό επιλογής/διαμόρφωσης CIC μέσω ανάλυσης πραγματικών PSC δεδομένων, συνδυάζοντας:

• Grey Relational Analysis (GRA)

• Technique for Order Preference by Similarity to Ideal Solution (TOPSIS)

• Τον κανόνα Three-Sigma (3σ) για ανάδειξη των κωδικών ελλείψεων με «εξαιρετικά» υψηλή συχνότητα. Σύμφωνα με το paper, τα δεδομένα του Paris MoU περιλαμβάνουν 21 ship types και 496 deficiency codes, για περίοδο 36 μηνών (1/11/2018–31/10/2021).

2. Στόχος και ερευνητικό ερώτημα

Στόχος του Μέρους Α της εργασίας είναι η αναπαραγωγή του βασικού αλγοριθμικού μοντέλου του paper, χρησιμοποιώντας πραγματικά δεδομένα PSC του Paris MoU, όπως ορίζει η εκφώνηση.

Συνοπτικά, το ερευνητικό ερώτημα διατυπώνεται ως εξής:

Πώς μπορούμε, με βάση την ιστορική συχνότητα ελλείψεων ανά τύπο πλοίου, να ιεραρχήσουμε τα εξής:

(α) Τους τύπους πλοίων που τείνουν να εμφανίζουν περισσότερα ή κρισιμότερα προβλήματα

(β) Τους κωδικούς ελλείψεων που θα έπρεπε να αποτελούν προτεραιότητα στο πλαίσιο μιας CIC, έτσι ώστε να μειωθούν «τυφλά σημεία» της παραδοσιακής, μονοθεματικής επιλογής CIC

Η παρούσα υλοποίηση καλύπτει το Μέρος Α (αναπαραγωγή), όπως ζητήθηκε.

3. Περιγραφή δεδομένων και πηγών

3.1 Πηγή δεδομένων: Paris MoU THETIS-PSC

Για την αναπαραγωγή χρησιμοποιούνται τα διαθέσιμα αρχεία επιθεωρήσεων PSC για τα έτη 2018–2021, τα οποία παρέχονται από τον file server του Paris MoU μέσω API.

Η υλοποίηση αυτοματοποιεί:

(α) τη λήψη (download) των αρχείων zip

(β) την αποσυμπίεση (unzip)

(γ) την εύρεση XML αρχείων, και (δ) το parsing των XML για εξαγωγή (ship type, deficiency code) σε επίπεδο επιθεώρησης.

3.2 Σχήμα (schema) και βασικές μεταβλητές

Η ανάλυση βασίζεται σε δύο βασικές κατηγορίες μεταβλητών (dimensions):

• **Τύπος πλοίου (Ship Type)**: Κατηγορική μεταβλητή που περιγράφει την κλάση-τύπο του πλοίου (Για παράδειγμα: bulk carrier, general cargo/multipurpose). Στο XML schema εντοπίζεται στο μονοπάτι Inspection → ShipParticulars → ShipType, συχνά ως attribute Value.

• **Κωδικός έλλειψης (Deficiency Code):** Κατηγορικός κωδικός που αντιστοιχεί σε συγκεκριμένο αντικείμενο-κατηγορία ελέγχου και έλλειψης (π.χ. 07105, 15150 κ.λπ.).

Οι κωδικοί ελλείψεων αντιστοιχούν σε θεματικές σειρές (01000, 07000, 15000) όπως αναφέρονται και στο paper.

3.3 Αναπαράσταση δεδομένων ως πίνακας συχνοτήτων (matrix)

Για να εφαρμοστούν οι αλγόριθμοι GRA , TOPSIS , Three-Sigma, τα δεδομένα μετασχηματίζονται σε πίνακα συχνοτήτων:

• Γραμμές: ship types (m)

• Στήλες: deficiency codes (n)

• Τιμές: πλήθος εμφανίσεων κάθε deficiency code για κάθε ship type.

Η συγκεκριμένη αναπαράσταση αντιστοιχεί στον πίνακα απόφασης (decision matrix) που χρησιμοποιεί το paper, όπου τα κριτήρια είναι οι κωδικοί ελλείψεων και τα εναλλακτικά αντικείμενα αξιολόγησης είναι οι τύποι πλοίων.

4. Συνοπτική αρχιτεκτονική λύσης και ροή εργασίας

Η λύση οργανώθηκε σε δύο βασικά αρχεία:

1) **data.py**: Pipeline απόκτησης των δεδομένων από το API και στην συνέχεια προετοιμασίας δεδομένων και παραγωγής του pivot matrix (ship_type × deficiency_code).

2) **notebook.ipynb**: Πειραματισμός και υλοποίηση των αλγορίθμων (GRA, TOPSIS, Three-Sigma) πάνω στο matrix, μαζί με ενδεικτικές οπτικοποιήσεις και συγκρίσεις.

Η ροή εργασίας, από την αρχή μέχρι το τέλος, είναι:

(1) Απόκτηση δεδομένων
(2) Εντοπισμός XML
(3) Parsing & εξαγωγή μεταβλητών
(4) Aggregation σε counts
(5) Δημιουργία matrix
(6) Εφαρμογή αλγορίθμων & εξαγωγή rankings/ευρημάτων.

5. Υλοποίηση απόκτησης και μετασχηματισμού δεδομένων (data.py)

5.1 Αυθεντικοποίηση και λήψη αρχείων μέσω API

Η κλάση **ParisMouClient** υλοποιεί έναν client για πρόσβαση στον file server του Paris MoU:

1. Αποκτά token αυθεντικοποίησης (Μέσω του getauthorizationtoken) χρησιμοποιώντας το API key.
2. Κάνει caching του token και ανανέωση, ώστε να μειώνονται οι κλήσεις και να αποφεύγονται αποτυχημένες λήψεις λόγω λήξης.
3. Κατεβάζει τα αρχεία zip μόνο αν δεν υπάρχουν τοπικά, εξοικονομώντας χρόνο σε επαναληπτικά runs.

Το API key διαβάζεται από μεταβλητή περιβάλλοντος PARISMOU_API_KEY (μέσω .env) για λόγους ασφάλειας και φορητότητας (χωρίς hard-coded κλειδιά).

5.2 Αποσυμπίεση και εντοπισμός XML

Μετά τη λήψη, κάθε zip αποσυμπιέζεται σε ξεχωριστό φάκελο. Στη συνέχεια, γίνεται αναζήτηση αρχείων με κατάληξη .xml, ώστε ο κώδικας να μην εξαρτάται από μια σταθερή δομή φακέλων μέσα στο zip.

Η επιλογή αυτή επιτρέπει robustness σε πιθανές μελλοντικές αλλαγές της εσωτερικής δομής των αρχείων που παρέχει το Paris MoU (Επιπλέον υποφακέλους).

5.3 Parsing XML με iterparse και διαχείριση μνήμης

Η επεξεργασία XML γίνεται με **xml.etree.ElementTree.iterparse** σε events=("end",) και στοχεύει σε στοιχεία τύπου <Inspection>.

Σημεία τεχνικής επιλογής:

• Το iterparse επιτρέπει streaming επεξεργασία (δεν φορτώνεται ολόκληρο το XML στη μνήμη).

• Μετά την επεξεργασία κάθε <Inspection>, γίνεται elem.clear(), απελευθερώνοντας τη μνήμη και αποτρέποντας memory blow-up σε μεγάλα αρχεία.

Η προσέγγιση είναι κατάλληλη για «big data» αρχεία XML (πολλά εκατομμύρια nodes), όπου η πλήρης φόρτωση είναι απαγορευτική.

5.4 Εξαγωγή ShipType

Η extract_ship_type εντοπίζει το ShipType με βάση το schema: Inspection → ShipParticulars → ShipType.

Κύριος κανόνας: **Διαβάζει το attribute Value του ShipType (όταν υπάρχει).**

Fallback: Αν δεν υπάρχει το attribute, διαβάζει το κείμενο (text) του element.

Επιστρέφει None αν δεν βρεθεί ship type, ώστε η ροή να συνεχίσει χωρίς σφάλμα, και χωρίς να δημιουργούνται λανθασμένα ζεύγη τύπου (ship_type, deficiency_code).

5.5 Εξαγωγή Deficiency Code

Οι deficiency codes στο XML ενδέχεται να εμφανίζονται με διαφορετικό τρόπο (attribute, text, nested tags).

Για να υπάρχει ανθεκτικότητα , η extract_deficiency_code υλοποιεί πολλαπλούς κανόνες:

1) Έλεγχος attributes του node Deficiency: Αν κάποιο attribute περιέχει 'code' στο όνομα ή ισούται με 'Value', επιστρέφεται ως code.

2) Έλεγχος child tags: Αναζήτηση descendant tags που περιέχουν 'code' στο όνομα. Αν βρεθεί, προτιμάται το text του tag, αλλιώς το attribute Value.

3) Τελικό fallback: Έλεγχος για attribute Value απευθείας στο Deficiency element.

Με αυτόν τον τρόπο μειώνονται οι απώλειες εγγραφών σε περιπτώσεις schema drift, namespaces ή διαφορετικής κωδικοποίησης.

5.6 Aggregation: μέτρηση συχνοτήτων και παραγωγή matrix

Κατά το parsing υπολογίζονται τα ακόλουθα:

1. **pair_counts[(ship_type, deficiency_code)]** = πλήθος εμφανίσεων του κωδικού στο συγκεκριμένο ship type.
2. **shiptype_counter**: πόσες επιθεωρήσεις ανά ship type (για βασικά descriptive stats).
3. **defcode_counter**: Συνολικές εμφανίσεις ανά deficiency code.

Επιπλέον καταγράφονται:

- **inspections_total**: πλήθος επιθεωρήσεων που διαβάστηκαν.
- **inspections_with_def**: πόσες από αυτές είχαν τουλάχιστον μία έλλειψη.

Μετά το parsing όλων των XML, τα αποτελέσματα εξάγονται σε:

1. sparse CSV (triples: ship_type, deficiency_code, count)
2. pivot CSV (matrix): ship_type ως index, deficiency_code ως columns, με fill_value=0.

Το pivot matrix αποτελεί την είσοδο για τους αλγορίθμους GRA/TOPSIS/Three-Sigma.

6. Προετοιμασία δεδομένων και περιγραφική ανάλυση (notebook.ipynb)

6.1 Φόρτωση matrix και βασικά στατιστικά

Στο notebook φορτώνεται το matrix CSV, δημιουργώντας ένα pandas DataFrame όπου:

• Η πρώτη στήλη είναι το ship_type

• Οι υπόλοιπες στήλες είναι οι deficiency codes ως strings

• Οι τιμές είναι ακέραια πλήθη.

Αρχικά παράγεται μια απλή οπτικοποίηση: άθροισμα ελλείψεων ανά ship type (bar plot), ώστε να γίνει μια πρώτη «αίσθηση» της κατανομής και να εντοπιστούν πιθανά dominants ship types.

6.2 Ορισμός decision matrix E και alternatives A

Για την εφαρμογή των αλγορίθμων:

• A: διάνυσμα εναλλακτικών (ship types) από τη στήλη ship_type.

• E: αριθμητικός πίνακας (m × n) με τις συχνότητες, χωρίς τη στήλη ship_type.

Το E μετατρέπεται σε numpy array float όπου απαιτείται από τους υπολογισμούς (ιδίως στην TOPSIS).

7. Συνοπτική θεωρία και υλοποίηση αλγορίθμων

7.1 Grey Relational Analysis (GRA)

Η Grey Relational Analysis (GRA) είναι μέθοδος της Grey System Theory και χρησιμοποιείται για τη μέτρηση του βαθμού συσχέτισης και εγγύτητας μεταξύ μιας «reference sequence» και πολλών «comparative sequences», όταν η πληροφορία είναι ατελής ή αβέβαιη.

Στο πλαίσιο του προβλήματος:

1. Κάθε ship type αποτελεί ένα συγκριτικό αντικείμενο (comparative sequence) πάνω στα κριτήρια deficiency codes.
2. Η reference sequence επιλέγεται ως το ιδανικό προφίλ συχνοτήτων (Για παράδειγμα το μέγιστο ανά κριτήριο), ώστε να εκτιμηθεί ποιος τύπος πλοίου προσεγγίζει περισσότερο το «ιδανικά υψηλό» επίπεδο εμφάνισης ελλείψεων.

Βασικά βήματα (όπως υλοποιούνται):

1) Κανονικοποίηση (Min-Max) του πίνακα E: $x_i(k) \in [0, 1]$ 2)
2) Ορισμός reference sequence: $x_o(k) = \max_i x_i(k)$
3) Υπολογισμός απόλυτων αποκλίσεων: $\Delta_i(k) = |x_o(k) - x_i(k)|$
4) Συντελεστής συσχέτισης (grey relational coefficient): $\gamma_i(k) = (\Delta\min + \xi \cdot \Delta\max) / (\Delta_i(k) + \xi \cdot \Delta\max)$, όπου $\xi \in (0,1)$ (συνήθως 0.5) 5) Grey relational grade ανά ship type: Γ_i = average_k $\gamma_i(k)$

Έξοδος: Ένα score (grade) ανά ship type και κατάταξη (descending).

7.1.1 Σημεία υλοποίησης στο notebook

Η υλοποίηση στο notebook χρησιμοποιεί sklearn.preprocessing.MinMaxScaler για κανονικοποίηση.

Το αποτέλεσμα αποθηκεύεται σε πίνακα GRA_results και ταξινομείται ώστε να προκύψει η τελική κατάταξη (finalGRA).

7.2 TOPSIS

Η TOPSIS (Technique for Order Preference by Similarity to Ideal Solution) είναι μέθοδος επιλογής, όπου το καλύτερο αντικείμενο είναι αυτό που:

• Είναι όσο το δυνατόν πιο κοντά στην θετική ιδανική λύση (best)

• Όσο το δυνατόν πιο μακριά από την αρνητική ιδανική λύση (worst).

Στο πρόβλημα:

• **Alternatives**: ship types

• **Criteria**: deficiency codes

• **Αξίες**: συχνότητες εμφάνισης ελλείψεων (μεγαλύτερο = εντονότερη παρουσία προβλήματος).

Βασικά βήματα:

1) Κανονικοποίηση ανά κριτήριο (vector normalization): $r_ik = x_ik / sqrt(\Sigma_i x_ik^2)$

2) Ορισμός ιδανικών λύσεων: $best_k = max_i\ r_ik$ $worst_k = min_i\ r_ik$

3) Υπολογισμός αποστάσεων (Euclidean): $S_i^+ = sqrt(\Sigma_k\ (r_ik - best_k)^2)$ $S_i^- = sqrt(\Sigma_k\ (r_ik - worst_k)^2)$

4) Συντελεστής εγγύτητας (closeness coefficient): $C_i = S_i^- / (S_i^+ + S_i^-)$

Κατάταξη:

Μεγαλύτερο C_i ⇒ πιο κοντά στο ideal best ⇒ υψηλότερη προτεραιότητα (στην ερμηνεία του paper: ship types που εμφανίζουν πιο «βαριά» και εκτεταμένα patterns ελλείψεων).

7.2.1 Σημεία υλοποίησης στο notebook

Στην υλοποίηση:

• Το E μετατρέπεται σε float numpy array.

• Οι divisors υπολογίζονται ανά στήλη ώστε να γίνει vector normalization.

• Για αποφυγή division-by-zero, όπου divisor==0 αντικαθίσταται με 1 (πρακτικό safeguard σε στήλες που ενδέχεται να είναι μηδενικές).

Το αποτέλεσμα εξάγεται σε DataFrame TOPSIS με:

• S Best (S^+), S worst (S^-), και C (closeness coefficient), και ταξινομείται φθίνουσα ως προς C.

Παράγεται επίσης οριζόντιο bar chart (TOPSIS ranking) και scatter plot για σύγκριση GRA vs TOPSIS.

7.3 Three-Sigma Rule (κανόνας 3σ)

Ο κανόνας Three-Sigma χρησιμοποιείται ως απλός αλλά ισχυρός μηχανισμός ανίχνευσης συχνών deficiency codes.

Εφαρμογή στο πρόβλημα:

• Για κάθε deficiency code k, υπολογίζεται το συνολικό πλήθος εμφανίσεων σε όλα τα ship types: SUM_k.

• Υπολογίζεται ο μέσος όρος μ των SUM_k και η τυπική απόκλιση σ.

• Ένας κωδικός θεωρείται «σημαντικός» αν SUM_k > μ + 3σ.

Το paper αξιοποιεί το three-sigma ώστε να εντοπιστούν inspection items που ανοίγονται πολύ συχνά από PSCO και άρα αποτυπώνουν κοινά προβλήματα.

7.3.1 Σημεία υλοποίησης στο notebook

Στην υλοποίηση:

• Υπολογίζεται διάνυσμα sum = Σ_i E_ik (άθροισμα ανά κωδικό).

• mean = mean(sum)

• sigma εκτιμάται από το άθροισμα τετραγώνων αποκλίσεων, διαιρώντας με 495 (n-1 όπου n=496) και παίρνοντας τετραγωνική ρίζα.

Έπειτα, υπολογίζονται thresholds για 3σ έως 6σ και εξάγονται οι κωδικοί που ξεπερνούν κάθε όριο.

Τέλος, δημιουργείται ένα μικρό υποσύνολο (final) με επιλεγμένους κωδικούς, και απεικονίζεται ως heatmap έναντι των ship types, για άμεση οπτική κατανόηση του πού συγκεντρώνονται οι ελλείψεις.

8. Ερμηνεία αποτελεσμάτων και σύνδεση με το paper

Το paper δείχνει ότι ο συνδυασμός GRA και TOPSIS παρέχει συμπληρωματική πληροφορία:

• GRA: αναδεικνύει ποια ship types παρουσιάζουν ισχυρή συσχέτιση με το συνολικό «προφίλ» ελλείψεων

• TOPSIS: κατατάσσει τα ship types ως προς την εγγύτητα σε ένα ιδανικό προφίλ υψηλών ελλείψεων ανά κριτήριο, ενώ το three-sigma αναδεικνύει τους κωδικούς που ξεπερνούν σημαντικά το «μέσο» επίπεδο συχνότητας.

Στην αναπαραγωγή, η ίδια λογική ακολουθείται με τον pivot πίνακα (ship type × deficiency code). Η σύγκριση των δύο rankings (GRA vs TOPSIS) στο notebook (μέσω merge και ranks) βοηθά να επιβεβαιωθεί ότι οι κορυφαίοι ship types είναι σταθερά ψηλά και στις δύο μεθόδους, όπως αναφέρει και το paper για general cargo/multipurpose και bulk carrier.

Στο three-sigma μέρος, οι κωδικοί που ξεπερνούν το 3σ θεωρούνται υποψήφιοι CIC inspection items (ή υποψήφια deficiency series) γιατί εμφανίζονται με εξαιρετικά υψηλή συχνότητα. Στο paper, η χρήση rolling window τριών ετών στοχεύει να αντιμετωπίσει την αδυναμία της παραδοσιακής CIC επιλογής

(single series, προηγούμενο έτος), η οποία μπορεί να χάνει σημαντικούς κωδικούς ή να καθυστερεί να πιάσει νέες τάσεις.

9. Συμπεράσματα

Η αναπαραγωγή του μοντέλου του paper ολοκληρώνεται με επιτυχία, καθώς:

1. Γίνεται πλήρης pipeline απόκτησης και μετασχηματισμού PSC δεδομένων σε matrix μορφή
2. Εφαρμόζονται οι αλγόριθμοι GRA και TOPSIS για κατάταξη ship types
3. Εφαρμόζεται ο κανόνας Three-Sigma για ανάδειξη deficiency codes με εξαιρετικά υψηλή συχνότητα
4. Παρέχεται σύγκριση των αποτελεσμάτων GRA vs TOPSIS, όπως προτείνει η βιβλιογραφία.

Σε επίπεδο τεχνικής υλοποίησης, κρίσιμα στοιχεία είναι:

1. streaming επεξεργασία XML (iterparse + clear) για αποδοτικότητα
2. Η εξαγωγή κωδικών από πιθανές παραλλαγές schema
3. Καθαρός διαχωρισμός «data engineering» (data.py) από «αλγοριθμική ανάλυση» (notebook).

Ως επόμενο βήμα (εκτός του Μέρους Α) θα μπορούσαν να προστεθούν επιπλέον χαρακτηριστικά (π.χ. χώρα σημαίας, λιμένας, επιθεωρητική αρχή, χρονικές τάσεις) και να υλοποιηθεί ο rolling CIC μηχανισμός πλήρως όπως προτείνεται στο paper.

Αναλυτικότερη περιγραφή αλγορίθμων και παραδείγματα υπολογισμού

1 GRA – Παράδειγμα με μικρό πίνακα

Για να γίνει πιο κατανοητή η GRA, παρουσιάζεται ένα μικρό παράδειγμα με 3 ship types (A1–A3) και 4 deficiency codes (C1–C4). Θεωρούμε ότι ο πίνακας συχνοτήτων (counts) είναι:

A1: [10, 0, 2, 8] A2: [3, 1, 0, 4] A3: [7, 2, 1, 1]

Βήμα 1 – Min-Max κανονικοποίηση ανά κριτήριο: Για κάθε στήλη εφαρμόζουμε: x' = (x - min)/(max - min). Έτσι, όλες οι τιμές γίνονται συγκρίσιμες στο [0,1].

Βήμα 2 – Reference sequence: Στην υλοποίηση επιλέγεται ως reference το μέγιστο ανά στήλη, δηλαδή $x0(k) = \max_i x_i(k) \Rightarrow [1, 1, 1, 1]$ μετά την κανονικοποίηση.

Βήμα 3 – Αποκλίσεις και grey coefficients: Υπολογίζονται $\Delta_i(k) = |x0(k) - x_i(k)|$, εντοπίζονται Δmin και Δmax στο σύνολο του πίνακα, και παράγονται οι συντελεστές $\gamma_i(k)$ με ξ=0.5.

Βήμα 4 – Grey grade: Ο τελικός δείκτης για κάθε A_i είναι ο μέσος όρος των $\gamma_i(k)$. Η κατάταξη προκύπτει ταξινομώντας τα grades φθίνουσα.

Στο πραγματικό dataset, το μικρό παράδειγμα γενικεύεται σε m=21 ship types και n=496 deficiency codes, όπως στο paper.

2 TOPSIS – Παράδειγμα και ερμηνεία του Closeness Coefficient

Στην TOPSIS, το C_i (closeness coefficient) έχει σαφή ερμηνεία:

• Αν $C_i \approx 1$, το αντικείμενο είναι πολύ κοντά στη θετική ιδανική λύση (best) και μακριά από τη worst.

• Αν $C_i \approx 0$, το αντικείμενο είναι κοντά στη worst.

Με δεδομένο ότι στο συγκεκριμένο πρόβλημα όλα τα κριτήρια είναι benefit (μεγαλύτερα counts ⇒ μεγαλύτερη προτεραιότητα επιθεώρησης), το best_k ορίζεται ως μέγιστο ανά κριτήριο στο normalized space.

Στην πράξη, αυτό σημαίνει ότι:

• ένα ship type με υψηλές συχνότητες σε πολλούς κωδικούς θα έχει μικρό S^+ και μεγάλο S^- ⇒ υψηλό C.
• ένα ship type με χαμηλές συχνότητες θα έχει μεγάλο S^+ και μικρό S^- ⇒ χαμηλό C.

Σημείωση: Η κλασική TOPSIS περιλαμβάνει συχνά βάρη κριτηρίων (weights). Στην αναπαραγωγή δεν χρησιμοποιούνται βάρη (όλα τα κριτήρια ισοβαρή), επειδή η εκφώνηση του Μέρους Α στοχεύει στην αναπαραγωγή της βασικής λογικής χωρίς πρόσθετες επιλογές παραμετροποίησης.

D.3 Three-Sigma – γιατί 3σ και πώς χρησιμοποιείται για επιλογή inspection items

Ο κανόνας 3σ είναι κλασικός κανόνας ανίχνευσης ακραίων τιμών (outliers) όταν μια κατανομή είναι κανονική ή όταν θέλουμε ένα απλό, συντηρητικό όριο.

Στην προκειμένη περίπτωση δεν απαιτείται αυστηρή κανονικότητα.

Η λογική είναι επιχειρησιακή:

• Οι deficiency codes με SUM_k > μ + 3σ είναι τόσο συχνοί, που είναι πολύ πιθανό να αποτελούν κοινό σημείο για επιθεωρήσεις και άρα έχουν υψηλή χρησιμότητα για στοχευμένη δράση (CIC).

Το paper αναφέρει ότι ο three-sigma βοηθά να εντοπιστούν οι κωδικοί που ανοίγονται με υψηλή συχνότητα από PSCO, δηλαδή αντικείμενα στα οποία υπάρχει υψηλότερη «συναίνεση» ως προς τον έλεγχο.

Στο notebook υπολογίζονται και αυστηρότερα thresholds (4σ–6σ) για να φανεί πόσο συμπαγές είναι το σύνολο των κορυφαίων κωδικών. Αυτή η κλιμάκωση είναι χρήσιμη όταν θέλουμε να περιορίσουμε το πλήθος inspection items σε ένα πρακτικά διαχειρίσιμο πακέτο.