ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
ΤΜΗΜΑ ΨΗΦΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ
Μεταπτυχιακό Πρόγραμμα Σπουδών
"Πληροφοριακά Συστήματα & Υπηρεσίες"

UNIVERSITY OF PIRAEUS
DEPARTMENT OF DIGITAL SYSTEMS
Postgraduate Program
"Information Systems & Services"

ΚΑΤΕΥΘΥΝΣΗ: Μεγάλα Δεδομένα και Αναλυτική

ΜΑΘΗΜΑ: Προγραμματισμός και Υποδομές Μεγάλων Δεδομένων: Python και Νεφοϋπολογιστική

Ομαδική Εργασία Ακαδ. Έτους 2025-2026

1. Γενικά

Η εργασία αυτή θα σας βοηθήσει να εξοικειωθείτε με τις βασικές έννοιες του προγραμματισμού σε Python μέσω της ενασχόλησης με ένα πραγματικό πρόβλημα με χρήση πληθώρας διαφορετικών τεχνικών.

Η ασφάλεια της ναυτιλίας αποτελεί κρίσιμο παράγοντα για τη διεθνή οικονομία, το περιβάλλον και την ανθρώπινη ζωή στη θάλασσα. Για την εξασφάλιση υψηλών προτύπων ασφαλείας, τα κράτη εφαρμόζουν ένα σύστημα επιθεωρήσεων σε πλοία που καταπλέουν στα λιμάνια τους **Port State Control (PSC)**, ώστε να εντοπιστούν ελλείψεις, παραβάσεις κανονισμών ή συνθήκες που μπορεί να θέσουν σε κίνδυνο το πλοίο, το πλήρωμα, το φορτίο ή το περιβάλλον.

Στην Ευρώπη και τον Ατλαντικό, ο συγκεκριμένος θεσμός λειτουργεί στο πλαίσιο του **Paris Memorandum of Understanding (Paris MoU)**[1]. Το Paris MoU συλλέγει, καταγράφει και δημοσιεύει χιλιάδες επιθεωρήσεις ετησίως, δημιουργώντας ένα από τα πιο πλούσια και αξιόπιστα σύνολα δεδομένων **ασφάλειας ναυτιλίας** διεθνώς.

Τα δεδομένα αυτά περιλαμβάνουν:

1. πληροφορίες για το πλοίο (π.χ. τύπος, ηλικία, σημαία, φορέας κλάσης, εταιρεία)
2. αποτελέσματα επιθεωρήσεων,
3. καταγεγραμμένες ελλείψεις (deficiencies),
4. ιστορικό κρατήσεων (detentions),
5. δείκτες κινδύνου όπως το **Ship Risk Profile (SRP)**.

Η ανάλυση των παραπάνω δεδομένων έχει εξαιρετική σημασία, διότι συμβάλλει:

1. Στη **βελτίωση των πολιτικών επιθεώρησης** και στην ορθολογική κατανομή πόρων (στοχευμένες επιθεωρήσεις).
2. Στην **έγκαιρη αναγνώριση πλοίων "υψηλού κινδύνου"**, πριν συμβεί ατύχημα ή ρύπανση.
3. Στην ανάπτυξη **μοντέλων πρόβλεψης** για κρατήσεις, ελλείψεις ή γενικότερη ποιότητα/συμμόρφωση πλοίων με τους κανονισμούς.

[1] https://parismou.org/

4. Στην ενίσχυση της **διαφάνειας και βιώσιμης λειτουργίας της ναυτιλίας**, κάτι που ζητούν διεθνείς οργανισμοί όπως ο IMO[2].

Τα τελευταία χρόνια, ερευνητικές ομάδες από όλο τον κόσμο έχουν δημοσιεύσει πλήθος εργασιών σε έγκριτα επιστημονικά περιοδικά όπου συνδυάζουν τα δεδομένα του Paris MoU (ή/και άλλων περιφερειακών συμφωνιών (π.χ. Tokyo MoU) με **αλγορίθμους Τεχνητής Νοημοσύνης/Μηχανικής Μάθησης** (Bayesian Networks, Random Forests, SVM, Deep Learning, Πολυκριτηριακή ανάλυση (MCDA) κ.ά.) με στόχο την:

1. πρόβλεψη κράτησης (detention prediction),
2. εκτίμηση διάρκειας κράτησης,
3. ανίχνευση πλοίων που δεν πληρούν το αξιόπλοο (substandard ships),
4. ανάπτυξη εναλλακτικών δεικτών ρίσκου πέρα από το επίσημα καθιερωμένο SRP,
5. ανάλυση τάσεων και επιβάρυνσης ανά λιμάνι/σημαία/κατηγορία πλοίου.

Συγκεκριμένα στην εργασία θα πρέπει να **μελετήσετε, να αναπαράγετε και να επεκτείνετε** ένα από τα μοντέλα που έχουν παρουσιαστεί στη διεθνή βιβλιογραφία, χρησιμοποιώντας πραγματικά δεδομένα PSC από το Paris MoU.

2. Περιγραφή Εργασιών

Σε κάθε ομάδα θα ανατεθεί **ένα επιστημονικό άρθρο (paper)** από τη λίστα η οποία περιέχεται στο τέλος του κειμένου. Το άρθρο αυτό περιγράφει ένα μοντέλο/αλγόριθμο μηχανικής μάθησης ή πολυκριτηριακής ανάλυσης σχετικό με PSC δεδομένα.

Η εργασία σας αποτελείται από δύο βασικά μέρη (αυτά μπορούν σε μεγάλο βαθμό να προχωρούν παράλληλα από τα διαφορετικά μέλη μια ομάδας):

Μέρος Α — Αναπαραγωγή του βασικού αλγορίθμου από το paper

1. Θα μελετήσετε το επιλεγμένο paper και θα περιγράψετε
   - το πρόβλημα που επιχειρεί να λύσει,
   - το σύνολο δεδομένων που χρησιμοποιεί (μεταβλητές, χρονική περίοδος, πιθανή προεπεξεργασία που αναφέρεται),
   - τον αλγόριθμο/αλγόριθμους που προτείνει στα διάφορα στάδια που υλοποιεί (π.χ. Bayesian Network, Random Forest, SVM, MCDA, PCA).
2. Θα υλοποιήσετε σε Python τον βασικό αλγόριθμο του άρθρου με χρήση των βιβλιοθηκών python που κρίνετε απαραίτητες (μπορείτε να χρησιμοποιήσετε οποιαδήποτε βιβλιοθήκη επιθυμείτε):
3. Θα εκπαιδεύσετε το μοντέλο σε δεδομένα του **Paris MoU** του αρχικού paper και θα υπολογίσετε τις μετρικές εκτίμησης των αποτελεσμάτων του καθώς και πρόσθετες μετρικές αξιολόγησης όπως ενδεικτικά:
   - Ακρίβεια (Accuracy) / F1 / AUC (για classification)
   - RMSE / MAE / MAPE/ Απώλεια Huber (για regression)
   - Μετρικές εκτίμησης Συσταδοποίησης (π.χ. silhouette) (για clustering)
   - Ερμηνεία αποτελεσμάτων (explainability) (σημασία μεμονωμένων χαρακτηριστικών, SHAP, ανάλυση ευαισθησίας (sensitivity analysis))
4. Θα συγκρίνετε τα αποτελέσματά σας με τα αντίστοιχα του paper (όπου αυτό είναι εφικτό).

[2] https://www.imo.org/

Μέρος Β — Επέκταση / Βελτίωση του μοντέλου

Κάθε ομάδα θα υλοποιήσει **μία ουσιαστική επέκταση**, όπως:

- προσθήκη νέων χαρακτηριστικών (feature engineering),
- δοκιμή νέων αλγορίθμων και μεθοδολογιών (π.χ. Gradient Boosting, XGBoost, Neural Networks),
- βελτίωση αλγορίθμου (π.χ. κόστος/πέναλτι λάθους (cost-sensitive learning) για ιδιαίτερα μη ισορροπημένες κλάσεις (Class Imbalance), Κανονικοποίηση (regularization) για καταπολέμηση της υπερπροσαρμογής (overfitting) (π.χ. αποτροπή δημιουργίας πολύ βαθιών δέντρων), Εύρεση βέλτιστων υπερπαραμέτρων και αυτοματοποίηση της διαδικασίας με χρήση ενός pipeline
- εφαρμογή αλγορίθμου για την ερμηνεία της απόφασης (SHAP, PDP plots),
- εναλλακτική διαμόρφωση του προβλήματος (Σύγκριση μακροχρόνιου ή βραχυχρόνιου ρίσκου, διαφορετικά κατώφλια απόφασης π.χ. με χρήση ROC ή F1 score),
- σύγκριση μεταξύ του αλγορίθμου του μέρους Α, του αλγορίθμου της εργασίας καθώς και του αλγορίθμου που έχετε αναπτύξει στο μέρος Β στο σύνολο δεδομένων της αρχικής εργασίας (εφόσον είναι διαθέσιμο καθώς και στο σύνολο των δεδομένων που έχετε επιλέξει (μπορεί να έχετε επεκτείνει)
- Δημιουργία και δοκιμή ενός σύνθετου δείκτη ρίσκου (αν το paper π.χ. χρησιμοποιεί multivariate/MCDA).

Η επέκταση πρέπει να είναι τεχνικά τεκμηριωμένη και να οδηγεί σε **σαφές συμπέρασμα**: βελτιώνει ή όχι την απόδοση; είναι πιο ερμηνεύσιμο το νέο μοντέλο; πώς επηρεάζονται οι δείκτες ρίσκου; Είναι πιο αξιόπιστοι οι δείκτες επικινδυνότητας που προτείνατε εσείς

2. Μέθοδοι και Δεδομένα

Μπορείτε να χρησιμοποιήσετε οποιαδήποτε βιβλιοθήκη της python επιθυμείτε. Δώστε προσοχή στις παραμέτρους που δέχεται κάθε συνάρτηση / μέθοδος που θα χρησιμοποιήσετε.

Μπορείτε να εφαρμόσετε οποιαδήποτε μέθοδο επιθυμείτε από τη βιβλιογραφία. Κάντε αναφορά σε βιβλιογραφικές πηγές (π.χ. έτοιμα τμήματα κώδικα ή τεχνικές που χρησιμοποιήσατε).

Για να αποκτήσετε πρόσβαση στα δεδομένα του ParisMoU θα πρέπει να επικοινωνήσετε και να τους ζητήσετε πρόσβαση (**Η διαδικασία μπορεί να καθυστερήσει οπότε φροντίστε να γίνει η αίτηση έγκαιρα!**)

3. Παραδοτέα

Η εργασία που θα υποβάλλετε θα πρέπει να περιέχει τα ακόλουθα αρχεία

1. **Αρχείο ή Αρχεία κώδικα.** θα πρέπει να υποβάλλετε το αρχείο ή αρχεία κώδικα που αναπτύξατε για την επίλυση του προβλήματος. Σε περίπτωση που εφαρμόσατε διαφορετικές μεθοδολογίες στην προσπάθεια σας να λύσετε το πρόβλημα καλό είναι να περιέχονται οι διαφορετικοί κώδικες και να περιέχει η εργασία τη σύγκριση μεταξύ των διαφόρων προσεγγίσεων που πραγματοποιήσατε. Ο κώδι-

κας/ οι κώδικες που θα αναπτύξετε θα πρέπει να παράγει ενδεχόμενα διαγράμματα που περιλαμβάνει η αναφορά σας και η παρουσίαση σας. Ο κώδικας θα πρέπει να είναι επαρκώς σχολιασμένος.

2. **Παρουσίαση.** Τις διαφάνειες που θα παρουσιάσετε για την εργασία. Μπορείτε να χρησιμοποιήσετε όσες διαφάνειες επιθυμείτε ή και οποιαδήποτε άλλη μορφή παρουσίασης ωστόσο ο διαθέσιμος χρόνος θα έχει άνω όριο 10 λεπτά (μπορείτε να χρησιμοποιήσετε λιγότερο από αυτόν) και θα διατεθούν και 5 λεπτά για 2-3 ερωτήσεις. Στην παρουσίαση σας θα πρέπει να περιλάβετε τα κυριότερα αποτελέσματα σας, τεχνικές που χρησιμοποιήσατε, περιορισμούς του προγράμματος σας καθώς και ότι άλλο επιθυμείτε στο παραπάνω χρονικό όριο.
3. **Αναφορά.** Η αναφορά σας θα έχει **μέγιστο** μέγεθος **15 σελίδες Α4** με τη διάταξη που σας εξυπηρετεί καλύτερα και τύπο/μέγεθος γραμματοσειράς του σώματος κειμένου Calibri 11. Η αναφορά σας θα πρέπει να περιέχει τουλάχιστον τα ακόλουθα μέρη
    a. Εξώφυλλο
    b. Πίνακα περιεχομένων
    c. Περιγραφή του προβλήματος και των διαθέσιμων δεδομένων
    d. Συνοπτική Περιγραφή του συστήματος που αναπτύξατε και των τεχνικών που επιλέξατε και συνοπτική περιγραφή των κυριότερων μερών του κώδικα και ιδίως μερών που είχατε την κυριότερη συμβολή (π.χ. τμήματα κώδικα τα οποία αναπτύξατε εσείς).
    e. Αποτελέσματα : Αποτελέσματα, γραφήματα. Στην αναφορά καλό είναι να συμπεριλάβετε διαγράμματα, πίνακες για ενδιάμεσα και τελικά αποτελέσματα (π.χ. περιγραφικά στατιστικά για τα δεδομένα σας)
    f. Συμπεράσματα: Συνολικός σχολιασμός – αποτίμηση αποτελεσμάτων της εργασίας σας, περιορισμοί, βελτιστοποιήσεις που κάνατε, πιθανές επεκτάσεις. Στην περίπτωση που το πρόβλημα που επιλέξετε συνοδεύτηκε από υποβολή σε διαγωνισμό του Kaggle να το δηλώσετε και να υποβάλλετε και screenshot από τη σελίδα υποβολής.

Στο σύνολο των σελίδων δεν προσμετρώνται τα a-b. Πίνακες και γραφήματα που δεν θα περιέχονται στην παρουσίαση σας (παραδοτέο 2) μπορούν να συμπεριληφθούν σε παραρτήματα τα οποία επίσης δεν προσμετρώνται στο σύνολο των σελίδων.
Τα αρχεία της εργασίας θα πρέπει να υποβληθούν ως ένα συμπιεσμένο (.zip) αρχείο αποκλειστικά σε ηλεκτρονική μορφή μέσω του eclass (ενότητα Εργασίες) έως την καταληκτική ημερομηνία που θα καθοριστεί εκεί.

Καλή Επιτυχία!